

项目建议书 V2：面向 Holo Agent 的反应核意识流架构

日期：2026-05-24

项目名称

反应核意识流：面向持久化 LLM Agent 的输入-理解-决策-行动-反馈仿生架构

版本说明

V2 在上一版基础上强化“项目围绕的核心问题”。上一版已经确立 Holo 的基本方向：以 LLM 为语言处理核心，以工作记忆、长期记忆、视觉观察、工具行动、反馈学习和可视化 trace 构建类人心智过程的工程模型。V2 将研究焦点进一步收束：Holo 要解决的首要问题集中在系统层，关键是如何把一次次有限上下文的 provider 调用组织成连续、可记忆、可行动、可自我修正、可观察的心智流程。

摘要

本项目的目标是尽可能建模人类心智在语言、记忆、感知、行动和反馈中的连续过程。人类与 LLM 在语言处理层面表现出高度相似性：都能够在有限上下文中完成语义压缩、意图推断、关系判断、隐含信息补全和表达生成。由此产生一个关键问题：如果 LLM 已经具备很强的语言处理能力，为什么单个 LLM 调用通常没有表现出宏观层面的意识流、主体连续性和自我修正能力？

Holo 将这一问题转化为系统架构问题来研究。我们把 LLM 看作语言处理模块，把本地 Holo 主脑看作状态保持、记忆调度、工具行动、视觉观察、反馈回写和可视化分析的闭环系统。项目要寻找的结构是：当语言处理模块被放入怎样的外层架构中，整个系统会表现出更接近人类心智的第一反应、延迟思考、连续表达、记忆沉积、行动反馈和自我改进。

本项目提出“反应核意识流模型”（Reaction-Kernel Conscious Stream Model, RK-CSM）。模型假设人类式第一反应可以近似表示为反应核作用于上下文、工作记忆、长期记忆、情绪/驱动状态、视觉状态、任务压力和过往反馈形成的综合状态场。第一反应进入工作记忆，改变系统状态，并触发继续门控。若任务仍未完成，Holo 可以继续调度更深层的推理包、检索包、工具包或视觉观察包；若后续表达缺少新的语义功能，系统抑制外显输出。每个外显片段必须承担清晰功能，例如快速确认、澄清、纠错、解释、承诺、工具执行反馈或阶段性总结。

项目围绕的核心问题

本项目围绕一个中心问题展开：

当 LLM 已经具备强语言处理能力时，怎样的外层认知架构能够把一次次有限上下文的 provider 调用组织成连续、可记忆、可行动、可自我修正、可观察的类人心智过程？

这个问题同时具有理论意义和工程意义。理论上，它触及人类心智如何从局部语言处理、记忆、感知、行动和反馈中涌现出连续主体表现。工程上，它决定 Holo 是否能从聊天接口发展为稳定的个人/实验室 Agent。单次 provider 调用很像一次局部神经活动，能力很强，持续性有限。宏观心智表现需要更高层的组织结构：状态场、工作记忆、长期记忆、行动闭环、感知入口、反馈沉积、继续门控和自我修复机制。

该中心问题可以分解为七个可研究的子问题。

1. 状态问题：Holo 的“当前状态”应如何表示，才能同时容纳用户刚刚说的话、长期记忆、任务目标、情绪/驱动状态、视觉观察和工具结果。
2. 发包问题：Holo 应如何决定给 provider 发什么包、包有多长、使用 flash 模型还是 reasoner、什么时候继续发包、什么时候停止。
3. 记忆问题：短期工作记忆和长期记忆应如何协作，才能让用户刚刚提出的约束和多日以前的稳定事实同时发挥作用。
4. 行动问题：工具调用、文件读取、命令执行、视觉观察和记忆写入应如何进入同一个认知闭环，使行动结果改变下一轮思考。
5. 表达问题：Holo 的一次回答可能由 A'、A''、A''' 组成，后续片段应由模型主脑根据任务状态自主决定，并通过语义新颖度门控避免机械复述。
6. 学习问题：用户纠正、失败案例、工具错误和记忆冲突应如何沉积为反应核参数、记忆权重和调度策略的更新。
7. 观测问题：研究者应如何实时看到 Holo 的状态变化、语义向量迁移、记忆激活、工具回路和继续门控，进而判断系统是否形成连续心智轨迹。

围绕这个问题，Holo 的目标可以表述为：建立一个以 LLM 为语言处理核心、以本地主脑为连续状态组织者、以多通道感知和工具行动为外部身体接口的仿生 Agent 系统。人类意识的理解与技术系统的发展可以同步推进；Holo 的价值在于把意识流、记忆、行动和反馈这些抽象概念放入可实验、可复现、可消融的工程结构。

为什么这个问题有趣

这个问题有趣，首先因为它把“LLM 为什么没有稳定宏观意识表现”从哲学争论转化为可实验的系统问题。LLM 展现出强语义能力，说明语言处理本身已经达到很高水平。宏观意识表现的缺口可能

来自系统层：缺少持续状态、缺少身体化接口、缺少长期反馈、缺少行动后果、缺少自我维护结构。Holo 研究的正是这些结构如何组合。

其次，这个问题具有实际价值。一个能长期运行的 Agent 需要记住用户、理解任务、调用工具、观察环境、修正错误、控制成本、管理风险。普通聊天模型很难稳定承担这些职责。Holo 如果能把 provider 的语言能力稳定封装进连续认知流程，就可以成为真实可用的个人/实验室 Agent。

第三，这个问题适合形成论文。它有清晰研究对象、可实现系统、可采集数据、可构造基线、可做消融实验、可提出指标，也能用可视化展示内部状态。它连接 Agent memory、test-time compute、tool use、context learning、world models 和认知科学中的工作记忆/长期记忆/反馈学习问题。

背景阅读材料

项目将重点检查以下方向：

1. 语言 Agent 的认知架构。CoALA 将语言 Agent 组织为记忆、行动空间和决策过程等模块，可为 Holo 的模块化内核提供理论参照。 <https://arxiv.org/abs/2309.02427>
2. 生成式 Agent 与反思机制。Generative Agents 说明观察、记忆检索、规划和反思对可信行为有重要作用。 <https://arxiv.org/abs/2304.03442>
3. 分层记忆和虚拟上下文管理。MemGPT 将 LLM Agent 看作具有多层记忆和上下文调度能力的系统，与 Holo 的 working/candidate/durable/archive 记忆结构具有相似问题意识。 <https://arxiv.org/abs/2310.08560>
4. 推理-行动闭环。ReAct、Reflexion、Tree of Thoughts 等工作表明，将推理、行动、反馈和记忆结合起来，可以提升 Agent 的任务表现和自我修正能力。 <https://arxiv.org/abs/2210.03629> <https://arxiv.org/abs/2303.11366> <https://arxiv.org/abs/2305.10601>
5. 世界模型和多模态行动模型。World Models、RT-2、Genie、V-JEPA 等工作提示我们，未来 Agent 需要逐步引入视觉、环境和行动反馈。 <https://arxiv.org/abs/1803.10122> <https://arxiv.org/abs/2307.15818> <https://arxiv.org/abs/2402.15391> <https://ai.meta.com/blog/v-jepa-yann-lecun-ai-model-video-joint-embedding-predictive-architecture/>
6. DeepSeek reasoner 与工具调用文档。当前 Holo 接入中，DeepSeek reasoner 暂时作为文本/推理模块使用；实时图像信息需要由外部视觉算法、摄像头管线或多模态模型先转化为场景描述、对象状态、事件摘要和 embedding，再进入 Holo 的状态场。 https://api-docs.deepseek.com/guides/reasoning_model

数据来源与采集方式

项目将使用四类数据。

第一类是对话和交互日志，包括 Holo CLI、WeChat、独立会话端和系统调试过程中的输入输出。数据内容包括用户输入、Holo 回复、回复分段、时间间隔、选择的行动、用户纠正和失败记录。

第二类是内部 trace 数据，包括每次发包的元数据、激活的记忆锚点、向量检索结果、继续门控值、语义新颖度、工具调用请求、工具返回结果和自我反思记录。这类数据是研究意识流可视化和状态连续性的关键。

第三类是多模态观察数据。DeepSeek 暂时不承担原生实时视觉处理；多模态由 Holo 在系统层外接。初期可以从本机摄像头采集低频快照或短帧窗口，用外部视觉算法生成场景描述、物体状态、环境变化和视觉 embedding。默认保存经过压缩和脱敏的状态表示，原始视频仅在明确实验需求和显式许可下保留。

第四类是评测数据，包括人工构造的对话场景、记忆召回测试、工具调用任务、视觉 grounding 任务、长周期连续性测试，以及自回声、重复表达、幻觉记忆、错误工具调用等失败案例。

数据采集坚持本地优先、可回放、可匿名化和可删除原则。公开实验使用合成数据、脱敏样例或派生指标。

方法与算法设计

RK-CSM 在每个时间步从 CLI、WeChat、摄像头、文件、工具结果等通道接收输入 x_t ，并构建综合状态场：

$$S_t = \text{Phi}(x_t, C_t, W_t, M_t, A_t, V_t, G_t, O_t)$$

其中：

- C_t 表示当前对话上下文；
- W_t 表示工作记忆和当前线程状态；
- M_t 表示长期记忆、候选记忆和检索锚点；
- A_t 表示情绪、驱动、压力和社会姿态；
- V_t 表示视觉或多模态场景状态；
- G_t 表示目标、承诺和任务世界状态；
- O_t 表示过往行动结果、错误和用户反馈。

第一反应可以表示为：

```
R_t^0 = K_theta (*) S_t
```

K_{θ} 是反应核，代表系统长期形成的反应倾向、表达约束、风险偏好、关系先验和行动偏置。它属于 Holo 本地可更新的状态参数层，可由用户反馈、失败案例、长期互动和自我反思逐步调整。

第一包完成后，系统写入状态增量：

```
Delta S_t^0 = observe(R_t^0, selected_action, visible_reply, internal_packet)
```

继续门控判断下一步：

```
continue_t = g(uncertainty, novelty_gap, unfinished_task, tool_need, affect_pressure,  
risk, user_wait_cost)
```

门控关闭时，系统停止输出。门控打开时，Holo 可调度更深模型，例如 DeepSeek reasoner。第二包必须携带第一包已经完成的语义功能、尚未完成的任务、需要避免重复的内容和可能调用的工具。外显 bubble 只有在具备明确新功能时才出现，例如澄清、纠错、追问、解释、承诺、工具执行、风险提示或总结。

发包策略遵循三个原则：

1. 快速包优先给足上下文。flash 模型承担意图判断、状态摘要、浅层回复建议和继续门控建议。
2. 深层包由状态驱动。reasoner 或 pro 模型只在不确定性高、工具需求强、记忆冲突明显或任务仍未完成时调度。
3. 每包都回写状态。无论用户是否看到该包，内部 trace 都记录其输入、输出、门控、工具请求和状态增量。

系统实现路线

项目复用现有 Holo runtime。WSL Holo host 保持唯一主脑；Windows、WeChat、摄像头和未来移动端都作为传输层或感知层接入。可复用模块包括：

- processor fabric 多模型通道；
- memory warehouse 和 memory fabric；
- working/candidate/durable/archive 记忆层；
- 工具调用适配器；
- CLI 与 WeChat transport；
- DeepSeek provider backend；

- thought-flow trace 与 CT 可视化工作台。

在此基础上，项目将新增或强化：

1. 反应核状态参数层；
2. 每包后的 state-delta 记录；
3. 语义新颖度和冗余度评分；
4. 多 bubble 的语义角色门控；
5. 意识流 CT 工作台；
6. 摄像头输入与视觉场景状态；
7. DeepSeek reasoner 的条件调用；
8. 工具调用与反馈写回；
9. 自我反思和自我修复流程。

可视化设计

可视化是本项目的研究仪器。系统应提供类似仿生 CT 的工作台，展示：

- 当前输入通道和时间；
- 激活的记忆锚点及强度；
- 工作记忆场在每次发包前后的变化；
- 反应核的激活情况；
- 继续推理门控值；
- 多个 bubble 之间的语义新颖度；
- 被选择的行动和被抑制的候选行动；
- 工具调用图；
- 视觉场景 embedding 和变化；
- 记忆写入深度。

这些图形化指标用于区分连续状态轨迹和多个孤立文本片段。可视化还应支持回放，使研究者能够检查某次回复为什么走向重复、幻觉、沉默、工具失败或记忆错配。

评测方案

实验比较以下系统：

- 单次大模型调用基线；
- 普通 RAG 基线；

- 固定两句回复基线；
- 无 state-delta 的多包推理基线；
- 完整 RK-CSM 系统。

主要指标包括：

- 回复片段之间的语义新颖度；
- 重复率和同义复述率；
- 短期记忆约束保持率；
- 长期记忆召回准确率；
- 幻觉记忆率；
- 工具调用成功率与误调用率；
- 延迟和 token 成本；
- 用户纠正后的采纳率；
- 多日连续对话中的一致性；
- 摄像头接入后的视觉 grounding 准确率；
- 高权限工具的安全门控准确率。

消融实验

计划进行以下消融：

1. 移除反应核，观察第一反应一致性和风格稳定性变化；
2. 移除工作记忆写回，观察第二包是否退化为同义复述；
3. 移除语义新颖度门控，测量重复 bubble 增加情况；
4. 移除长期记忆检索，测量记忆召回错误率；
5. 移除情绪/驱动状态，评估语气和社会适配能力；
6. 移除视觉场景状态，评估多模态任务下降情况；
7. 仅使用 flash 模型，比较成本、延迟和质量；
8. 禁用 reasoner，评估复杂任务中的计划质量下降；
9. 禁用工具调用，评估任务完成率和幻觉率；
10. 禁用自我反思，评估用户纠正后的恢复能力。

失败情况与能力边界

本项目以可观测行为、状态连续性和反馈改进作为研究对象。真实主观体验无法由当前实验直接证明，因此评价重点放在宏观心智表现的可测指标上：连续性、意向性、记忆正确性、行动责任和自我修正能力。

可能失败的情况包括：记忆污染、过度拟合某种人格语气、幻觉式回忆、过度继续发包、工具误用、视觉误读、自回声、隐私泄漏和成本失控。系统还可能把仿生表达发展成过度拟人化语言，需要通过提示约束、评测和可视化监控加以控制。

摄像头接口尤其需要谨慎。默认要求用户显式开启，并显示采集状态。初期优先保存派生描述和 embedding，原始视频只在明确实验需求下启用。涉及人脸、私人屏幕、实验数据和聊天内容时，需要脱敏和本地处理优先。高风险工具调用必须经过权限确认和审计记录。

预期贡献

本项目的预期贡献是提出并实现一个围绕 LLM 语言处理模块构建的仿生闭环系统：反应核、工作记忆状态更新、继续门控、reasoner 发包、工具/视觉行动、反馈写回和 CT 式可视化。该系统可用于研究 provider-based LLM Agent 如何在不训练基础模型的情况下，通过外层认知架构提升连续性、可靠性和实际行动能力。

从应用角度看，Holo 将成为具有长期记忆、多模态感知、工具行动和自我改进能力的个人/实验室 Agent。从科研角度看，Holo 可以作为研究人类心智建模、Agent memory、test-time compute、工具调用、视觉世界模型接入和意识流可视化的实验平台。若实验证明 RK-CSM 在重复率、记忆正确性、工具成功率、用户纠正采纳率和长周期一致性上优于现有基线，则该工作具备形成论文、系统 demo 和后续开源基准的潜力。